


2024-하계 집중이수제 주간학습보고서 (4주차)

창의과제	Unsupervised domain adaption 이미지 Segmentation 알고리즘 연구				
이름	김이나	학습기간	2024.07.15 ~ 2024.07.21		
학번	21011647	학습주차	4주차	학습시간	12
학과(전공)	컴퓨터공학과	과목명	자기주도창의전공III	수강학점	3
※ 수강학점에 따른 회차별 학습시간 및 10회차 이상 학습 준수					
금주 학습목표	<p>성능 향상 위한 새로운 방법론 (논문)survey - 1 가설 설정 : PODA optimization시 synthesis image를 활용하여 domain gap을 줄인다.</p>				
학습내용	<p><ZoDi: Zero-Shot Domain Adaptation with Diffusion-Based Image Transfer></p> <p>도메인 적응 문제를 해결하기 위해 최신의 확산 모델을 활용하는 방법론을 제안한다. 이 논문은 Zero-Shot Domain Adaptation (ZSDA)문제를 다루며, 소스 도메인에서 학습된 모델을 타겟 도메인으로 직접적으로 전이시키는 것을 목표로 한다. ZoDi는 확산 기반 이미지 전이 기법을 사용하여 소스 도메인과 타겟 도메인 간의 차이를 줄이고, 이를 통해 타겟 도메인에서도 높은 성능을 발휘할 수 있도록 한다</p> <p>이를 위한 논문의 방법론은 아래와 같다.</p> 				



	<p>1. 확산 모델 기반 이미지 전이 ZoDi는 소스 도메인에서 타겟 도메인으로의 이미지를 전이하기 위해 diffusion model을 활용한다. 확산 모델은 원본 이미지에 노이즈를 추가하고 이를 제거하는 과정을 반복하여 새로운 이미지를 생성하는 생성 모델이다. ZoDi는 이를 활용하여 다음과 같은 단계를 수행한다.</p> <p>1) 노이즈 추가 및 제거, 2) 컨디셔닝 기법 사용, 3) 역확산 과정</p> <p>2. 타겟 도메인 데이터 생성 ZoDi는 소스 도메인 이미지의 타겟 도메인 스타일 변환을 통해 타겟 도메인 데이터를 생성합니다. 이 과정에서는 다음의 방법이 사용된다.</p> <p>1) 대량의 가상 타겟 이미지 생성, 2) 다양한 스타일 반영</p> <p>3. 분류기 재학습 생성된 타겟 도메인 데이터를 이용하여 기존의 분류기를 재학습시킨다. ZoDi는 이 단계에서 다음의 전략을 수행한다.</p> <p>1) 소스 도메인에서 학습된 모델 활용, 2) 대량의 타겟 이미지 사용, 3) 평가 및 피드백 루프</p> <p><Synthesis image를 활용한 optimization> driving in snow 타겟으로 생성된 이미지를 활용하여 text target loss 와 image target loss 로 Cityscape 데이터로 학습을 진행하였다. 각자 다른 synthesis image와 loss의 비율을 수정하며 성능 개선을 위해 여러 실험을 진행하였다.</p> <div data-bbox="328 1171 754 1447"> <pre>Overall Acc: 0.858403 Mean Acc: 0.576767 FreqW Acc: 0.770692 Mean IoU: 0.447724 0.4477241220562442</pre> </div> <p>44.77%의 성능을 달성하며 기존의 baseline인 43.9보다 0.9%의 성능 개선을 이루었다.</p>
학습방법	<p>[개별 논문 리뷰 및 노션 공유 페이지를 통한 정리] 개별 학습을 통하여 Zodi를 이해하는 시간을 가졌다. 이때, 공유 노션 페이지에 정리하여 협업 및 스터디에 도움이 되도록 하였다.</p> <p>[모델 학습 및 실험] 논문을 통해 배운 방법론 들을 개별적으로 모델에 적용하였다. Cityscape 데이터로 학습을 진행한 후 ACDC의 snow data 셋으로 테스트를 진행하며 각자의 실험 결과들을 공유하였다.</p>
학습성과 및 목표달성도	<p>100% ZoDi 논문을 리뷰하며 synthesis image를 활용하여 domain gap을 줄이는 방법론은 이해하였다. 이를 PODA 코드에 적용하여 Cityscape->ACDC 로 실험 결과를 확인하였다.</p> <p>기존의 baseline 43.9%에서 synthesis image에서 뽑은 feature의 loss를 0.5로 준 경우</p>



	44.77%로 0.9% 정도의 성능 향상이 있었다. 또한 다른 상황에서의 실험을 통해 rain의 경우 baseline의 42.31% 에서 43.48%로 1.17% 성능 향상을 확인하였다.
참고자료 및 문헌	https://arxiv.org/abs/2212.03241 https://arxiv.org/pdf/2403.13652 https://github.com/astra-vision/PODA
내주 계획	성능 향상 위한 새로운 방법론 (논문)survey - 2가설 설정 : text feature에 노이즈를 준다.

2024 년 7 월 21 일

지도교수

김세원

(인)